

シード固定と評価条件統一による再現性検証

— OpenDDE 4 ノード分散ファインチューニングの 3 回反復と limit 20 での評価 —

松澤 拓海

2026 年 8 月 18 日

Abstract

これまでの一連の実行で、同一設定のはずのラン間で結果が一致しない原因が 2 つ特定されていた：学習コードが乱数シードを固定していないこと、および評価の投入件数 `--limit` が起動経路によって異なっていたこと（Dockerfile は 16、手書き Slurm スクリプトとコードの既定値は 20）である。本報告ではこの 2 点を修正し（`torch.manual_seed(42 + rank)` の固定と評価の `--limit 20` 統一、コミット 588e6b1）、4 ノード 16 GPU の分散ファインチューニングを 3 回反復して、3 つのチェックポイントすべてを同一条件で FoldBench 抗体-抗原評価にかけた。結果：(1) 3 回の学習損失曲線はほぼ一致した（エポック平均の最大差 0.0019、シード固定前は無相関）。残差は非決定的 CUDA カーネルの丸め誤差の蓄積である。(2) 損失の回帰傾きは 3 回とも名目上有意な減少（ $p = 0.0035/0.0101/0.0045$ ）を示したが、同一シードの反復であり独立な確認ではない。(3) DockQ 評価（24 採点界面）では、微調整の効果は今回も検出されなかった（成功率：ベースライン 2/24 に対し微調整 3 ランは 1-2/24、ギャップ 0.0）。損失曲線がほぼ一致する 3 つのチェックポイントでも、界面単位の DockQ は最大 0.199 揺れており、閾値ベースの成功率がチェックポイントの微差に敏感であることが分かった。

1 背景：結果が一致しなかった 2 つの原因

1.1 乱数シードが固定されていなかった

もとの `src/train.py` には `torch.manual_seed` の呼び出しがなく、拡散学習のノイズ強度 σ のサンプリングと座標への付加ノイズが毎ラン別の値を引いていた。その帰結として、同一設定の 3 つの歴史的ラン（08-15 の記録・08-17 の再現・08-18 の再実行）でエポック平均損失の回帰 p 値は 0.49/0.17/0.021 と散らばり、単一ランの「有意な減少」はラン間で再現しなかった。

1.2 評価の `--limit` が起動経路で異なっていた

評価の採点対象数の不一致（08-15 の記録：14 assembly / 19 界面、08-17 の再現：18 / 24）は、乱数でもデータの置き場でもなく、`src/inference.py` の `--limit`（ターゲット表の先頭から投入する assembly 数の上限）の違いが原因だった。記録された結果は `docker/Dockerfile.eval` の CMD にハードコードされた `--limit 16` で実行され（ログに 16 targets from interface_antibody_antigen）、再現は手書き `infer.slurm` の `--limit 20`（コードの既定値と同値）で実行された。両者とも原子数超過（`--max-atoms 8000`）で同一の 2 件（8xnh: 15,706 原子、8up2: 10,632 原子）をスキップしており、 $14 = 16 - 2$ 、 $18 = 20 - 2$ で件数は完全に説明される。なお 16 という値は「20 から減らした」のではなく、初期イメージの `--limit 10` を `--max-atoms` 導入時に「スキップ後も採点数を確保するため」16 へ増やした経緯の産物である（第 1 実験リポジトリのコミット dda04e87 に明記）。

2 本報告での変更点

コミット 588e6b1 で次の 2 点のみを変更した。

- 学習シードの固定: `src/train.py` に `--seed` (既定 42) を追加し、学習開始時に `torch.manual_seed(seed + rank)` を実行する。ランク間は独立なノイズを引き、ラン間には同一のノイズ列を引く。
- 評価条件の統一: `docker/Dockerfile.eval` の `--limit` を 16 から **20** (コード既定値) へ揃え、公開チェックポイントと 3 回反復の微調整チェックポイント (`finetuned-seed42-r1/r2/r3.pt`、クラスタ固定パス `/data1/rkp00041/rku00122/opendde-multinode/checkpoints/` に配置) を同一ジョブで採点するよう拡張した。

学習は Seyval 経由で RIKYU クラスタ 4 ノード × GB200 4 基 = 16 GPU を使い、同一コミット・同一設定で 3 回実行した (run_id: `abde1288` / `48503fab` / `bf864ed2`、ジョブ時間 1717/1579/1622 秒、いずれも FULL_VALIDATION: PASS、学習データは共有キャッシュの同一 27 エントリ)。

3 学習の再現性：3 回の損失曲線はほぼ一致

Fixed-seed training loss: three repetitions nearly coincide

Rank-averaged mean diffusion loss per epoch, 4 nodes / 16 GPUs, `torch.manual_seed(42 + rank)`.
Max pairwise epoch difference across the three seeded runs: 0.0019 (mean 0.0007); residual is nondeterministic-kernel rounding.
The unseeded Aug-18 run is shown for contrast: without a seed, curves are uncorrelated between runs.




Figure 1: シード固定後の 3 回の学習損失 (青) と、固定前の 08-18 ラン (橙)。青の 3 本はほぼ重なり、点単位の最大差は 0.0019 (平均 0.0007)。橙はシードが異なるため別の軌跡を描く。

Table 1: シード固定 3 ランの損失統計。回帰はエポック番号に対する単回帰 ($n = 30$, $df = 28$)。

ラン	平均	初回 → 最終エポック	傾き / エポック	r^2	t	p 値
r1 (abde1288)	0.0448	0.0449→0.0344	-2.34×10^{-4}	0.266	-3.19	0.0035
r2 (48503fab)	0.0447	0.0442→0.0343	-1.97×10^{-4}	0.214	-2.76	0.0101
r3 (bf864ed2)	0.0448	0.0450→0.0346	-2.22×10^{-4}	0.254	-3.09	0.0045

シード固定の効果は明瞭である。3 ランのエポック平均損失は点単位で最大 0.0019 しか変わらず（固定前のラン間差はこの約 1 桁上で、曲線同士は無相関だった）、残る微差は非決定的 CUDA カーネル（アトミック加算や cuBLAS の非決定性）の丸め誤差が学習を通じて蓄積したものである。ビット単位の一致まで求めるなら `torch.use_deterministic_algorithms(True)` 等が必要になる。

回帰の傾きは 3 回とも負で名目上有意（表 1）だが、これは同一シードの 3 反復であって独立な標本ではない点に注意が要る。3 回の一致が示すのは「シード 42 のノイズ列に対してこの傾きが安定に再現される」ことであり、「ノイズ列によらず損失が減少する」ことの確認には複数シードでの独立反復が必要である。実際、シード固定前の 3 ラン（別ノイズ列）の傾きは -6.8×10^{-5} から -2.5×10^{-4} まで動いていた。

4 評価：limit 20 統一でも微調整の効果は検出されず

公開チェックポイント（baseline）と r1/r2/r3 の 4 つを、`--limit 20`・推論シード 42・MSA/テンプレート検索なしの同一条件で採点した。20 ターゲット中、原子数超過の 2 件（8xnh, 8up2）を除く 18 assembly・26 界面を試行し、うち 24 界面が採点された（7yv1 の 2 界面は 4 ラン共通で OpenStructure が対応を取れず未採点）。

Table 2: FoldBench 抗体-抗原評価（24 採点界面、limit 20）。「対ベースライン」は同一界面での DockQ の対応差の平均と改善数。

ラン	成功率 (> 0.23)	DockQ 平均	中央値	IDDT 平均	対ベースライン
baseline	8.33% (2/24)	0.0665	0.0275	0.683	—
r1	4.17% (1/24)	0.0639	0.0350	0.625	-0.0026 (12/24 改善)
r2	8.33% (2/24)	0.0700	0.0435	0.627	+0.0036 (12/24 改善)
r3	4.17% (1/24)	0.0586	0.0295	0.636	-0.0078 (10/24 改善)




Figure 2: DockQ の累積分布。4 本の曲線はほぼ重なり、acceptable 閾値（0.23、破線）を超えるのはベースラインで 2 界面、微調整 3 ランで 1-2 界面。

主要な観察は次のとおり。

- 微調整の効果は検出されない。最良の微調整ラン（r2）の成功率はベースラインと同値（ギャップ 0.0）で、対応差の平均も ± 0.008 以内、改善界面数も 10-12/24 と半数前後。「微調整の効果は現在の評価規模ではノイズと区別できない」というこれまでの結論は、条件を統一し反復しても変わらなかった。
- 閾値ベースの指標はチェックポイント微差に敏感。損失曲線がほぼ一致する 3 チェックポイントでも、界面単位の DockQ は中央値 0.024、最大 0.199（8ux6-1）揺れる。成功率の 1/24 対

Per-interface DockQ: baseline vs three seed-42 fine-tuned runs

24 scored antibody-antigen interfaces (limit 20), sorted by baseline DockQ. Dashed line: acceptable (0.23).
Replicate spread among the three same-seed runs: median 0.024, max 0.199 (8ux6-1).




Figure 3: 界面ごとの DockQ (ベースライン降順)。橙丸がベースライン、青の 3 記号が微調整 3 ラン。閾値付近の 8ux6-1 は 3 ラン間で 0.082–0.281 と揺れ、成功率の 1/24 と 2/24 の差はこの 1 界面の出入りで生じている。

2/24 の差は、閾値 0.23 をまたぐ 8ux6-1 の 1 界面の出入りそのものである。訓練損失の再現性が閉じても、下流の離散指標の再現性は自動的に閉じない。

- ベースラインの成功率は **limit 20** の他評価と一致する。本評価の baseline 8.33% (2/24) は 08-17 の再現評価と同値であり、§1 の `--limit` 説明と整合する (DockQ 平均の微差 0.0665 対 0.0744 は、推論シードが 42 で固定でも GPU 非決定性で界面単位の値が揺れるため)。

5 実行の記録

- 学習 3 ランと評価は同一コミット 588e6b1 から Seyval 経由で実行した。評価ジョブ (run_id c8c5dce9) は 4 チェックポイント分の推論とベースラインの採点まで完了した後、図生成の `import matplotlib` で失敗した (共有 venv に matplotlib が無い。従来の記録が成功していたのは、当時参照していた個人 venv には入っていたため)。リポジトリは変更せず、回収済みの予測ファイルをクラスタ上の作業領域に復元し、08-17 の再現評価と同じ `uv run --with matplotlib` 方式で `src.evaluate` のみ再実行して採点を完了した。
- 成果物はリポジトリの `.research/results/seed42_limit20/` 以下に、既存の記録 (08-15 の `baseline-pretrained/` 等) を上書きしない形で追加した: 各ランの `loss_curve.json`・`metrics.json`・`per_target_scores.csv` と `aggregated_metrics.json`。図は `.research/results/chart/` の `loss_seed42_replicates.pdf`・`dockq_cumulative_seed42.pdf`・`dockq_per_interface_seed42.pdf`。微調整チェックポイント 3 点 (各 2.6 GB) は Seyval のランおよび `/data1/rkp00041/rku00122/opendde-multinode/checkpoints/` にある。

6 結論と提言

シード固定により、学習損失レベルの再現性は実用上閉じた (ラン間差 ≤ 0.0019)。評価の `--limit` を 20 に統一したことで、採点件数の食い違い (14/19 対 18/24) も解消し、以後の評価は直接比較できる。一方で、(1) 損失の「有意な減少」は同一シード内での再現に留まり、ノイズ列に対する頑健性は未確認、(2) DockQ 成功率は閾値付近の 1 界面の出入りで 2 倍変わる粒度しかなく、チェックポイントの丸め誤差レベルの差にも反応する。微調整の効果を主張・棄却するには、複数シードでの独立反復と、採点界面数を桁で増やした評価 (全 172 界面など) が必要である。

作成: 2026-08-18 / 松澤 拓海 (実行・集計は Claude Code + AIRAS/Seyval MCP)。リポジトリ: `auto-res2/matsuzawa-20260815-opendde-multinode-longrun-3` (コミット 588e6b1)。統計: 回帰は両側 t 検定 ($df = 28$)。DockQ 閾値 0.23 = CAPRI acceptable。